

PROJETO APLICADO ||

Sumário

	Página
1) Organização Escolhida	2
2) Apresentação dos Dados	2
3) Objetivos e Dados	2
4) Desenvolvimento.....	3
❖ Definição da Linguagem de Programação Usada no Projeto:	3
❖ Análise Exploratória da Base de Dados:	3
❖ Tratamento da Base de Dados:	4
❖ Definição e Descrição das Bases Teóricas dos Métodos:	4
❖ Definição e Descrição de Como Será Calculada a Acurácia:	4
5) Conclusão e Retomada de Resultados	6
❖ Método Analítico	6
❖ Medidas de Acurácia	6
6) Análise e Storytelling.....	6
❖ Descrição dos Resultados Preliminares	6
❖ Esboço do Storytelling	7

Gustavo Guarizzo Esteves RA: 10424491

Devido a problemas de comunicação, não consegui me alocar nos grupos formados. Sinta-se à vontade para me alocar se achar necessário. Reconheço a importância do trabalho em equipe, mas não consegui me integrar a tempo e não considero justo ficar sem nota por conta desse ocorrido. Agradeço a compreensão!

1) ORGANIZAÇÃO ESCOLHIDA

Empresa: OpenAI

Área de atuação: Desenvolvimento de Inteligência Artificial

Descrição: A OpenAI é uma empresa referência no desenvolvimento de tecnologias de inteligência artificial, com foco em modelos de linguagem, visão computacional e robótica. O seu produto mais conhecido, o **ChatGPT**, é amplamente utilizado para **assistência em linguagem natural** e avançado em questões de visão computacional, ajudando empresas e indivíduos em diversas tarefas como atendimento ao cliente, automação de processos, criação de conteúdo e mais.

2) APRESENTAÇÃO DOS DADOS

Fonte: Dataset contendo reviews do ChatGPT coletados de diferentes plataformas de usuários ("[CHATGPT USER REVIEWS \(kaggle.com\)](https://www.kaggle.com/datasets/openai/chatgpt-user-reviews)") **Colunas principais:**

- Review: Textos, de comentários tanto positivos quanto negativos.
- Label: Indica se o comentário é positivo ou negativo.

Descrição dos Dados: O dataset consiste em reviews feitos por usuários do ChatGPT, onde eles descrevem suas experiências com o produto, fornecendo uma avaliação e comentários detalhados. Esses dados são fundamentais para analisar o desempenho do ChatGPT, identificar padrões de satisfação e pontos a melhorar.

3) OBJETIVOS E DADOS

Objetivo Geral: Analisar as avaliações e reviews do ChatGPT para entender os padrões de satisfação dos usuários e identificar áreas para otimização do modelo.

Objetivos específicos:

1. Realizar uma análise de sentimentos nos comentários dos usuários para entender as emoções predominantes.
2. Identificar correlações entre as avaliações e o tipo de feedback textual fornecido.
3. Propor recomendações para melhorar a experiência do usuário e a eficácia do ChatGPT.

Link para o Github do Projeto:

- https://github.com/GustavoGuarizzo/Projeto_Aplicado_II

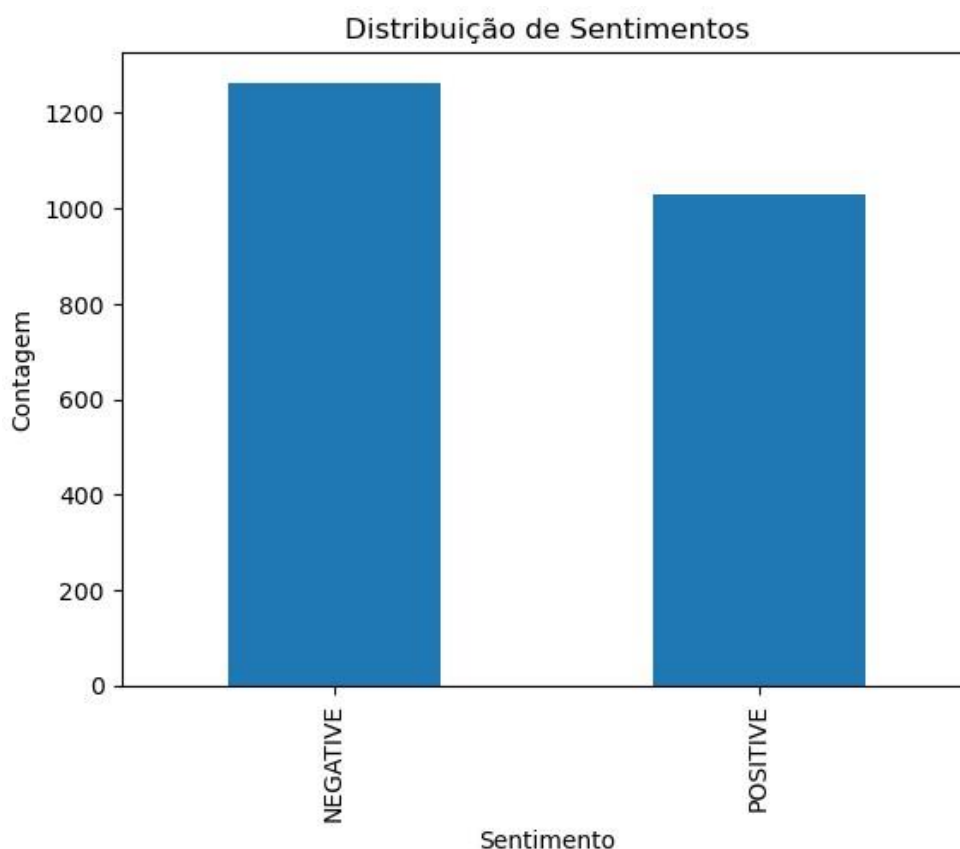
4) DESENVOLVIMENTO

❖ Definição da Linguagem de Programação Usada no Projeto:

A linguagem escolhida para o projeto será **Python**, devido à sua vasta gama de bibliotecas para análise de dados e machine learning, como **Pandas**, **NumPy**, **Scikit-learn**, e **NLTK** para análise de sentimentos.

❖ Análise Exploratória da Base de Dados:

A análise focará na distribuição dos sentimentos dos usuários. A maior parte das reviews será classificada em positivas (label = POSITIVE) ou negativas (label = NEGATIVE). As reviews serão transformadas em **vetores numéricos** usando a técnica de **TF-IDF**, que considera a frequência das palavras para gerar representações numéricas dos textos.



Insights: Analisando este gráfico é possível observar que os dados estão bem distribuídos e que provavelmente esta diferença não vá afetar a eficácia do modelo, portanto, não será necessário fazer um balanceamento.

❖ Tratamento da Base de Dados:

A preparação dos dados envolve o uso da técnica TF-IDF para converter o campo Review em representações vetoriais que podem ser usadas para treinar o modelo de machine learning e remover os valores nulos da coluna “Review”.

Preparação dos Dados

- Transformar os labels em valores binários (0 e 1) e remoção de valores nulos.

```
# Removendo as linhas com valores NaN na coluna 'Review'
df = df.dropna(subset=['Review'])

# Mapeando os labels para valores binários (0 = NEGATIVE, 1 = POSITIVE)
df['label'] = df['label'].map({'NEGATIVE': 0, 'POSITIVE': 1})

# Separando as features (Review) e o target (Label)
X = df['Review']
y = df['label']

# Dividindo os dados em treino e teste (80% treino, 20% teste)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Transformando os textos em vetores numéricos usando TF-IDF
tfidf = TfidfVectorizer(max_features=5000)
X_train_tfidf = tfidf.fit_transform(X_train)
X_test_tfidf = tfidf.transform(X_test)
```

❖ Definição e Descrição das Bases Teóricas dos Métodos:

O método escolhido para análise é a **Regressão Logística**, que é amplamente utilizada para classificação binária, como a predição de sentimentos (positivo ou negativo). O modelo será avaliado com métricas como **Acurácia** e **F1-score** para garantir sua eficácia.

```
# Modelo de Regressão Logística
model = LogisticRegression()
model.fit(X_train_tfidf, y_train)

# Previsões no conjunto de teste
y_pred = model.predict(X_test_tfidf)
```

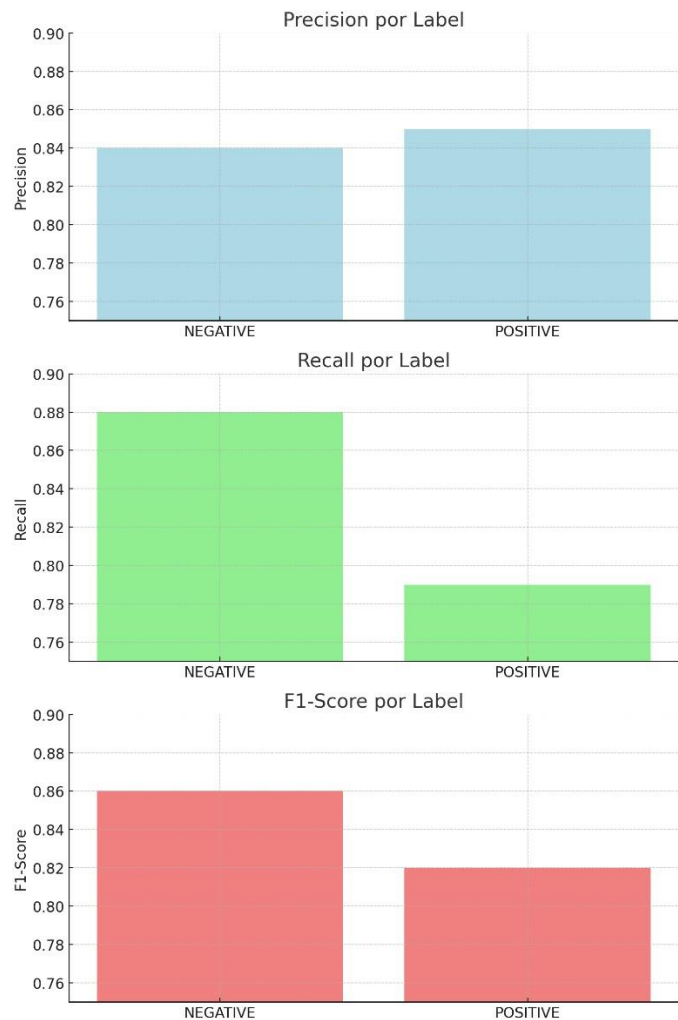
❖ Definição e Descrição de Como Será Calculada a Acurácia:

A acurácia será calculada usando a métrica de **accuracy_score** do pacote **sklearn**. A acurácia reflete a proporção de predições corretas sobre o total de predições. Além disso, será gerado um relatório de classificação com outras

métricas importantes, como **F1-score**, **Precisão** e **Recall** para avaliar o desempenho em detalhes.

Acurácia: 0.84				
	precision	recall	f1-score	support
NEGATIVE	0.84	0.88	0.86	249
POSITIVE	0.85	0.79	0.82	201
accuracy			0.84	450
macro avg	0.84	0.84	0.84	450
weighted avg	0.84	0.84	0.84	450

Insights: O modelo parece funcionar melhor na classificação de reviews negativos, com um maior recall (88%) em comparação aos positivos (79%). Isso pode indicar que o modelo tem mais facilidade em reconhecer críticas do que elogios.



Gráficos: Foram gerados gráficos mostrando os valores de **precision**, **recall** e **F1-score** para as classes "NEGATIVE" e "POSITIVE". Eles ajudam a visualizar as diferenças de desempenho entre as duas classes, mostrando que, apesar da

performance geral ser boa, o modelo tem um leve viés em classificar melhor os reviews negativos.

5) CONCLUSÃO E RETOMADA DE RESULTADOS

❖ Método Analítico

O método analítico definido na etapa anterior foi a Regressão Logística. Esse método foi aplicado à base de dados escolhida, que contém reviews do ChatGPT com a classificação de sentimentos (POSITIVO ou NEGATIVO). Os textos dos reviews foram convertidos em representações numéricas usando a técnica TF-IDF (Term Frequency-Inverse Document Frequency), que atribui pesos às palavras com base em sua frequência. Essa conversão permite treinar o modelo de Regressão Logística para prever se um review é positivo ou negativo, com base no texto fornecido.

❖ Medidas de Acurácia

As medidas de acurácia foram obtidas usando métricas como Acurácia e F1-score. A acurácia foi calculada com o uso da função `accuracy_score` do pacote `sklearn`, que reflete a proporção de predições corretas sobre o total de predições. Além disso, foram gerados gráficos para comparar o desempenho em termos de `precision`, `recall` e `F1-score` para as classes "NEGATIVE" e "POSITIVE". Observou-se que o modelo apresenta um maior `recall` para reviews negativos, com 88%, enquanto o `recall` para reviews positivos foi de 79%, indicando uma ligeira tendência do modelo em classificar melhor os reviews negativos.

6) ANÁLISE E STORYTELLING

❖ Descrição dos Resultados Preliminares

Os resultados preliminares indicaram que o modelo de Regressão Logística consegue classificar com boa precisão os reviews de usuários, com um leve viés em identificar críticas. Isso sugere que o modelo é eficaz em detectar áreas de melhoria com base nos comentários negativos dos usuários. O produto gerado pode ser um relatório de análise de sentimentos, destacando os principais pontos positivos e negativos mencionados pelos usuários. Esse relatório pode ser utilizado como parte de um modelo de negócios, focado em melhorar a experiência do usuário e a eficácia do ChatGPT, orientando decisões de desenvolvimento e marketing com base em feedbacks reais dos usuários.

❖ Esboço do Storytelling

O storytelling pode ser estruturado começando com o contexto da OpenAI e sua busca por melhorar a experiência do usuário com o ChatGPT. Em seguida, a narrativa aborda a análise dos dados de reviews dos usuários, passando pela aplicação do modelo de Regressão Logística para classificar os sentimentos dos reviews. A história deve destacar como insights valiosos foram obtidos para identificar padrões de satisfação e insatisfação dos usuários, propondo recomendações para melhorar o produto. Por fim, a conclusão pode abordar a utilidade dessa análise para decisões estratégicas e seu impacto na qualidade do serviço oferecido pela OpenAI.